

**PROPOSAL PROJECT AKHIR
PENGENALAN CITRA DIGITAL**

**KLASIFIKASI RETINOPATHY OF PREMATURITY
BERDASARKAN CITRA FUNDUS BAYI MENGGUNAKAN
SEGMENTASI PEMBULUH DARAH MANUAL DAN DEEP
LEARNING**

Kelompok 15

Anggota Kelompok

Ghiffari Bravia Hisham	G6401231050
Muhammad Abyan Putra Wibowo	G6401231078
Adam Naufal	G6401231082
Mochamad Chairulridjal Nurvikri	G6401231083
Rafif Muhammad Farras	G6401231102



**Program Studi Ilmu Komputer
Fakultas Matematika dan Ilmu Pengetahuan Alam
INSTITUT PERTANIAN BOGOR
BOGOR
2026**

Topik yang Dipilih

Kami memilih topik **klasifikasi citra MRI/medis untuk deteksi kategori kelainan**, dengan kasus khusus klasifikasi *Retinopathy of Prematurity* (ROP) dari citra fundus bayi. ROP merupakan gangguan retina pada bayi prematur yang dapat menyebabkan gangguan penglihatan serius apabila tidak ditangani. Pada citra fundus, struktur pembuluh darah retina menjadi salah satu sinyal visual penting karena perubahan dilatasi, tortuositas, dan pola vaskular dapat berkaitan dengan kondisi ROP, terutama *Plus disease*.

Kami memilih topik ini karena sesuai dengan cakupan project akhir Pengenalan Citra Digital: membangun sistem klasifikasi citra secara utuh dari praproses hingga evaluasi. Citra fundus bayi juga memiliki persoalan citra yang nyata, seperti variasi pencahayaan, kontras rendah, area latar hitam di luar retina, blur, noise, dan artefak perangkat. Kondisi tersebut memberi ruang bagi kami untuk menerapkan enhancement, segmentasi area penting, ekstraksi fitur, dan klasifikasi secara sistematis.

Dataset yang Dipilih

Dataset yang kami gunakan adalah *Retinal Image Dataset of Infants and Retinopathy of Prematurity* yang dipublikasikan oleh Timkovič et al. (2024). Ringkasan dataset ditunjukkan pada Tabel 1.

Tabel 1 Ringkasan dataset yang digunakan

Aspek	Keterangan
Nama dataset	<i>Retinal Image Dataset of Infants and Retinopathy of Prematurity</i>
Sumber ilmiah	Timkovič et al. (2024)
Tautan Kaggle	https://www.kaggle.com/datasets/jananowakova/retinal-image-dataset-of-infants-and-rop
Jumlah data	6.004 citra fundus dari 188 pasien bayi
Perangkat akuisisi	Clarity RetCam 3, Phoenix ICON, dan Natus RetCam Envision
Metadata/label	ID pasien, jenis kelamin, usia gestasional, berat lahir, usia postkonseptual, diagnosis, label <i>Plus form</i> , perangkat, seri pemeriksaan, dan nomor citra

Dalam project ini, kami menggunakan dua tugas klasifikasi karena keduanya melihat ROP dari sudut yang berbeda. Rincian tugas klasifikasi ditunjukkan pada Tabel 2.


Kami memilih dataset ini karena bersifat publik, relevan langsung dengan citra medis ROP, dan menyediakan label yang dapat digunakan untuk tugas klasifikasi. Tantangan utamanya adalah ketidakseimbangan kelas, variasi kualitas citra, serta kemungkinan korelasi antar citra dari pasien yang sama apabila evaluasi dilakukan pada tingkat citra.

Tabel 2 Tugas klasifikasi dan alasan pemilihannya

Tugas	Data dan distribusi kelas	Alasan kami gunakan
Plus disease	6.004 citra: 5.375 Normal/PF0 dan 629 Plus/PF2	Plus disease berkaitan langsung dengan perubahan morfologi pembuluh darah, sehingga cocok untuk menguji apakah segmentasi pembuluh benar-benar membawa informasi klasifikasi.
Stage ROP	880 citra: 45 Stage 0, 252 Stage 1, 458 Stage 2, dan 125 Stage 3	Klasifikasi stage membutuhkan konteks visual yang lebih luas, sehingga dapat menguji apakah informasi RGB dan mask pembuluh darah saling melengkapi.

Pipeline Project

Kami merancang pipeline mengikuti struktur minimum project akhir, yaitu akuisisi dataset, praproses, enhancement/restoration, segmentasi atau cropping area penting, ekstraksi fitur, pemodelan klasifikasi, evaluasi performa, dan analisis kekuatan serta kelemahan sistem.



Gambar 1 Alur umum pipeline project dari akuisisi dataset hingga evaluasi.

1. Akuisisi dan Pemahaman Dataset

Kami mengambil dataset dari sumber publik berdasarkan dataset Timkovic2024. Pada tahap awal, kami membaca seluruh file citra, mengekstraksi metadata dari nama file, membentuk label Plus disease dan Stage ROP, menghapus duplikasi apabila terdapat beberapa varian folder dataset, serta memeriksa distribusi kelas. Setelah itu, data dibagi menjadi train, validation, dan test menggunakan stratified split agar proporsi kelas tetap terjaga.

2. Praproses Data

Pada tahap praproses, kami membaca setiap citra RGB, melakukan resize ke ukuran input model, dan menormalisasi nilai piksel. Kami juga memisahkan field-of-view (FOV) retina dari area hitam di luar retina agar tahap thresholding dan ekstraksi fitur tidak dipengaruhi piksel latar. Pada tahap ini, kami mengecek kualitas data, termasuk citra yang terlalu gelap, blur, atau memiliki kontras rendah.


3. Enhancement / Restoration Citra

Kami melakukan enhancement untuk memperjelas struktur pembuluh darah retina. Metode utama yang digunakan adalah CLAHE pada ruang warna CIELAB agar kontras lokal meningkat tanpa mengubah warna secara berlebihan. Setelah itu, kami menggunakan kanal hijau sebagai dasar segmentasi karena pembuluh darah retina umumnya tampak lebih kontras pada kanal tersebut. Background normalization berbasis estimasi background halus diterapkan untuk mengurangi efek pencahayaan tidak merata.

4. Segmentasi Area Penting

Area penting yang kami fokuskan adalah pembuluh darah retina. Segmentasi pembuluh darah dilakukan secara manual berbasis pengolahan citra klasik, terinspirasi dari pendekatan segmentasi pembuluh darah pada citra ROP oleh Almeida et al. (2024). Pada tahap ini, kami menggunakan Bell-Shaped Gaussian Matched Filtering, modified top-hat multi-scale, kombinasi Frangi dan Jerman vesselness filter, Triangle thresholding, pembersihan artefak FOV dan optic disc, serta skeletonization untuk memperoleh struktur garis tengah pembuluh.

Kami memilih segmentasi manual agar komponen PCD terlihat eksplisit dan tidak sepenuhnya bergantung pada model deep learning. Mask pembuluh darah yang dihasilkan digunakan sebagai input pembanding pada model klasifikasi dan sebagai dasar analisis fitur pembuluh darah.



Gambar 2 Ilustrasi tahap enhancement dan segmentasi pembuluh darah manual.

5. Ekstraksi Fitur

Kami melakukan ekstraksi fitur dengan memanfaatkan dua representasi citra. Representasi pertama adalah citra RGB hasil praproses dan enhancement, yang mempertahankan informasi warna, tekstur, dan konteks visual retina. Representasi kedua adalah mask pembuluh darah hasil segmentasi manual, yang menonjolkan struktur vaskular sebagai fitur spasial tambahan untuk model CNN.

Selain fitur spasial untuk CNN, kami tetap menghitung fitur numerik seperti vessel density, skeleton density, estimasi ketebalan rata-rata pembuluh, jumlah endpoint, jumlah branchpoint, dan jumlah connected component sebagai bahan analisis. Fitur numerik ini tidak dijadikan pembeda utama antar skenario klasifikasi, tetapi membantu kami menjelaskan apakah citra dengan prediksi tertentu memiliki karakter pembuluh darah yang berbeda.

6. Pemodelan Klasifikasi

Kami menyusun pemodelan klasifikasi menjadi empat skenario dalam dua perbandingan terkontrol. Pada setiap pasangan A/B, hanya satu faktor utama yang diubah agar interpretasi hasil lebih jelas.

- **Plus A: citra RGB + CNN manual terinspirasi EfficientNetV2.** Skenario ini kami gunakan sebagai baseline untuk klasifikasi Normal/PF0 dan Plus/PF2 menggunakan citra fundus utuh. Model, split data, augmentasi, dan parameter training dibuat sama dengan Plus B.
- **Plus B: mask pembuluh darah + CNN manual terinspirasi EfficientNetV2.** Skenario ini memakai arsitektur dan setup training yang sama dengan Plus A, tetapi input RGB diganti dengan mask pembuluh darah yang direplikasi menjadi tiga kanal. Dengan demikian, perbedaan utama Plus A dan Plus B hanya pada representasi input: citra utuh atau struktur pembuluh darah.
- **Stage A: RGB + mask kosong dengan model dua cabang.** Skenario ini kami gunakan sebagai baseline untuk klasifikasi Stage 0–3. Arsitektur dua cabang tetap digunakan, tetapi cabang mask menerima mask kosong sehingga model pada praktiknya hanya memakai informasi RGB.
- **Stage B: RGB + mask pembuluh darah dengan model dua cabang.** Skenario ini memakai arsitektur, split data, augmentasi, dan parameter training yang sama dengan Stage A, tetapi cabang mask menerima mask pembuluh darah sebenarnya. Dengan demikian, perbedaan utama Stage A dan Stage B hanya pada keberadaan informasi pembuluh darah.

Dengan rancangan ini, kami ingin menjawab dua pertanyaan utama. Pertama, pada Plus disease, apakah citra utuh atau mask pembuluh darah lebih informatif jika modelnya sama? Kedua, pada Stage ROP, apakah penambahan informasi pembuluh darah meningkatkan klasifikasi stage jika arsitekturnya dibuat tetap?

Rancangan CNN mengadaptasi gagasan klasifikasi ROP berbasis deep learning oleh Vahidmoghadam et al. (2026), tetapi backbone klasifikasi tidak menggunakan model pre-trained. Kami membangun CNN manual yang terinspirasi dari EfficientNetV2 (Tan dan Le 2021), terutama melalui blok Fused-MBConv, MBConv, squeeze-and-excitation, aktivasi SiLU, dan global average pooling. Tahap segmentasi pembuluh darah juga dibuat manual agar tetap sesuai dengan fokus project PCD.

7. Evaluasi Performa


Kami mengevaluasi model menggunakan beberapa metrik karena dataset tidak seimbang. Accuracy tetap dilaporkan, tetapi tidak dijadikan satu-satunya ukuran keberhasilan. Rencana evaluasi ditunjukkan pada Tabel 3.

8. Analisis Hasil dan Pengembangan

Analisis tidak hanya berfokus pada akurasi akhir. Kami akan membahas alasan di balik hasil setiap skenario dengan menjaga interpretasi perbandingan A/B. Pada tugas Plus

Tabel 3 Rencana evaluasi performa model

Metrik evaluasi	Tujuan penggunaan	Catatan analisis
Accuracy	Mengukur proporsi prediksi benar secara umum	Dilaporkan sebagai gambaran awal, tetapi tidak cukup karena kelas tidak seimbang
Precision	Melihat ketepatan prediksi pada kelas positif atau kelas tertentu	Penting untuk mengetahui apakah model terlalu banyak memberi prediksi positif palsu
Recall / sensitivity	Melihat kemampuan model menangkap kelas yang seharusnya terdeteksi	Penting pada Plus disease karena kelas Plus lebih sedikit dan tidak boleh banyak terlewat
Specificity	Melihat kemampuan model mengenali kelas negatif atau non-kasus	Digunakan untuk melihat trade-off terhadap sensitivity, terutama pada tugas Plus disease
Macro F1-score	Merangkum precision dan recall dengan bobot seimbang antar kelas	Penting pada Stage ROP karena distribusi Stage 0–3 tidak seimbang
Confusion matrix	Menunjukkan pola kesalahan antar kelas	Dipakai untuk melihat kelas stage yang sering tertukar dan kesalahan Normal/Plus
ROC-AUC dan PR-AUC	Menilai kualitas skor probabilitas model	PR-AUC lebih diperhatikan pada Plus disease karena kelas Plus merupakan kelas minoritas



Gambar 3 Ilustrasi empat skenario klasifikasi. Stage A dan Stage B memisahkan CNN RGB dan CNN mask sebelum fitur digabungkan.

disease, analisis diarahkan untuk melihat apakah model CNN yang sama lebih terbantu oleh citra RGB utuh atau oleh mask pembuluh darah. Pada tugas Stage ROP, analisis diarahkan untuk melihat apakah penambahan mask pembuluh darah memberi peningkatan ketika arsitektur dan setup training dibuat tetap.

Kami juga akan melakukan analisis kesalahan dengan melihat contoh citra yang salah klasifikasi dan mengaitkannya dengan kualitas citra, hasil segmentasi pembuluh darah, imbalance kelas, serta kemiripan visual antar kelas. Perbandingan ini penting karena tujuan project bukan hanya memilih model dengan angka tertinggi, tetapi memahami peran setiap tahap PCD dalam pipeline klasifikasi.

Kelemahan yang perlu kami catat adalah ketidakseimbangan kelas, sensitivitas segmentasi manual terhadap kualitas citra, keterbatasan evaluasi apabila split masih berbasis image-level, serta belum adanya validasi klinis. Pengembangan lanjutan dapat mencakup tuning segmentasi, penghapusan artefak optic disc, patient-level split, tuning kapasitas CNN manual, dan validasi pada dataset eksternal.

Pustaka

- Almeida J, Kubicek J, Penhaker M, Cerny M, Augustynek M, Varysova A, Bansal A, Timkovic J. 2024. Enhancing ROP plus form diagnosis: An automatic blood vessel segmentation approach for newborn fundus images. *Results in Engineering*. 24:103054. doi:10.1016/j.rineng.2024.103054.
- Tan M, Le QV. 2021. EfficientNetV2: Smaller models and faster training. Di dalam: *Proceedings of the 38th International Conference on Machine Learning*, Volume ke-139, hlm 10096–10106.
- Timkovič J, Nowaková J, Kubíček J, Hasal M, Varyšová A, Kolarčík L, Maršolková K,

Augustynek M, Snášel V. 2024. Retinal image dataset of infants and retinopathy of prematurity. *Scientific Data*. 11(1):814. doi:10.1038/s41597-024-03409-7.

Vahidmoghadam M, Ghorbani P, Ahmadi MJ, Asadi Khameneh E, Tavassoli B, Taghirad HD. 2026. Automated diagnosis of plus form and early stages of ROP using deep learning models. *Scientific Reports*. 16(1):7234. doi:10.1038/s41598-026-37064-2.