

**KLASIFIKASI STAGE RETINOPATHY OF PREMATURITY
BERDASARKAN CITRA FUNDUS BAYI MENGGUNAKAN
ENHANCEMENT CITRA, SEGMENTASI PEMBULUH DARAH,
DAN CUSTOM CNN**

Kelompok 15

Anggota Kelompok

Ghiffari Bravia Hisham	G6401231050
Muhammad Abyan Putra Wibowo	G6401231078
Adam Naufal	G6401231082
Mochamad Chairulridjal Nurvikri	G6401231083
Rafif Muhammad Farras	G6401231102



**PROGRAM STUDI ILMU KOMPUTER
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
INSTITUT PERTANIAN BOGOR
BOGOR
2026**

ABSTRAK

GHIFFARI BRAVIA HISHAM, MUHAMMAD ABYAN PUTRA WIBOWO, ADAM NAUFAL, MOCHAMAD CHAIRULRIDJAL NURVIKRI, RAFIF MUHAMMAD FARRAS. Klasifikasi *Stage Retinopathy of Prematurity* Berdasarkan Citra Fundus Bayi Menggunakan *Enhancement* Citra, Segmentasi Pembuluh Darah, dan *Custom CNN*. Mata kuliah Pengenalan Citra Digital. Dibimbing oleh NAMA DOSEN.

Retinopathy of Prematurity (ROP) adalah gangguan perkembangan pembuluh darah retina pada bayi prematur yang berpotensi menyebabkan kebutaan jika tidak terdeteksi sejak dini. Penelitian ini membangun sebuah *pipeline* klasifikasi *stage* ROP dari citra fundus bayi ke lima kelas: Normal, Stage 1, Stage 2, Stage 3, dan bekas luka laser (*laser scars*). Proses dilakukan dalam dua tahap utama, yaitu segmentasi pembuluh darah secara klasik dan klasifikasi berbasis jaringan saraf tiruan. Pipeline segmentasi menggabungkan filter Gabor multiskala dengan respons Meijering berbasis matriks Hessian (konfigurasi *g40_m60_fine*), menghasilkan nilai Dice terbaik 0,4739 pada dataset HVDROPDB-BV. Model klasifikasi utama adalah *TinyResNetV2* yang dilatih dari awal tanpa bobot pra-latih, menerima masukan tiga kanal berupa *softmax* pembuluh darah, *softmax* area tepi, dan kanal hijau ternormalisasi CLAHE. Validasi silang 5-fold yang mempertimbangkan kelompok citra serupa (*group-aware cross-validation*) menghasilkan *macro F1-score* sebesar **0,7927**. Percobaan ablasi yang terkontrol menunjukkan bahwa representasi *softmax* memberikan peningkatan 0,1061 dibanding masukan RGB mentah (0,6866 vs 0,7927) pada model, data, dan protokol yang sama. Hasil ini membuktikan bahwa representasi spasial dari informasi pembuluh darah—bukan hanya nilai piksel mentah—merupakan kunci utama peningkatan performa klasifikasi *stage* ROP.

Kata kunci: *custom CNN*, *enhancement* citra, citra fundus, *Retinopathy of Prematurity*, segmentasi pembuluh darah, *TinyResNetV2*

ABSTRACT

GHIFFARI BRAVIA HISHAM, MUHAMMAD ABYAN PUTRA WIBOWO, ADAM NAUFAL, MOCHAMAD CHAIRULRIDJAL NURVIKRI, RAFIF MUHAMMAD FARRAS. Classification of Retinopathy of Prematurity Stages from Infant Fundus Images Using Image Enhancement, Vessel Segmentation, and Custom CNN. Digital Image Recognition Course. Supervised by NAMA DOSEN.

Retinopathy of Prematurity (ROP) is a vascular developmental disorder of the retina in premature infants that can lead to blindness if not detected early. This study constructs a classification pipeline for ROP staging from infant fundus images into five classes: Normal, Stage 1, Stage 2, Stage 3, and laser scars. The process consists of two main stages: classical vessel segmentation and neural network-based classification. The segmentation pipeline combines multiscale Gabor filters with

Hessian-based Meijering response (the *g40_m60_fine* configuration), achieving a best Dice score of 0.4739 on the HVDROPDB-BV dataset. The main classification model is TinyResNetV2 trained from scratch without pretrained weights, receiving a three-channel input consisting of vessel softmap, ridge softmap, and CLAHE-normalized green channel. Group-aware 5-fold cross-validation yields a macro F1-score of **0.7853**. A controlled ablation experiment demonstrates that the softmap representation provides a +0.0987 improvement over raw RGB input (0.6866 vs. 0.7853) under identical model, data, and protocol settings. These results confirm that spatial vessel evidence—rather than raw pixel values—is the key driver of classification performance improvement for ROP staging.

Keywords: custom CNN, image enhancement, fundus image, Retinopathy of Prematurity, vessel segmentation, TinyResNetV2

**KLASIFIKASI STAGE RETINOPATHY OF PREMATURITY
BERDASARKAN CITRA FUNDUS BAYI MENGGUNAKAN
ENHANCEMENT CITRA, SEGMENTASI PEMBULUH DARAH,
DAN CUSTOM CNN**

Kelompok 15

Anggota Kelompok

Ghiffari Bravia Hisham	G6401231050
Muhammad Abyan Putra Wibowo	G6401231078
Adam Naufal	G6401231082
Mochamad Chairulridjal Nurvikri	G6401231083
Rafif Muhammad Farras	G6401231102

Laporan Project Akhir
sebagai salah satu syarat penilaian mata kuliah
Pengenalannya Citra Digital pada
Program Studi Ilmu Komputer

**PROGRAM STUDI ILMU KOMPUTER
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
INSTITUT PERTANIAN BOGOR
BOGOR
2026**

DAFTAR ISI

DAFTAR TABEL	vi
DAFTAR GAMBAR	vi
DAFTAR LAMPIRAN	vi
I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Tujuan	2
1.4 Ruang Lingkup	2
1.5 Manfaat Penelitian	3
II TINJAUAN PUSTAKA	4
2.1 Retinopathy of Prematurity dan Tahapannya	4
2.2 Dataset Citra Fundus ROP	5
2.3 Praproses dan <i>Enhancement</i> Citra Fundus	6
2.4 Segmentasi Pembuluh Darah Retina	6
2.5 Klasifikasi ROP Berbasis <i>Deep Learning</i>	7
III METODE	9
3.1 Data dan Strategi Pembagian Data	9
3.2 Pipeline Segmentasi Pembuluh Darah	10
3.3 Skenario Representasi Input	11
3.4 Baseline Klasik: Fitur Rekayasa Manual	13
3.5 Arsitektur Model Klasifikasi: TinyResNetV2	13
3.6 Protokol Pelatihan	14
3.7 Metrik Evaluasi	15
IV HASIL DAN PEMBAHASAN	17
4.1 Hasil Segmentasi Pembuluh Darah	17
4.2 Hasil Baseline Klasik	17
4.3 Hasil Klasifikasi dengan Jaringan Saraf Tiruan	19
4.4 Pembahasan	21
V SIMPULAN DAN SARAN	24
5.1 Simpulan	24
5.2 Saran	24
DAFTAR PUSTAKA	26
LAMPIRAN	28

DAFTAR TABEL

1	Distribusi kelas pada dataset Zhao2024	9
2	Ringkasan kemajuan nilai Dice segmentasi pembuluh darah	11
3	Perbandingan <i>macro F1-score</i> antar pengklasifikasi pada baseline klasik (3 kelas: Stage 1, Stage 2, Stage 3)	18
4	Dua belas fitur terpenting pada model <i>Random Forest</i>	18
5	Ringkasan hasil eksperimen klasifikasi	19
6	Hasil model terbaik: <i>TinyResNetV2</i> dengan masukan softmax (group-aware CV)	20
7	Performa per kelas model terbaik (OOF, group-aware)	20

DAFTAR GAMBAR

1	Empat kategori kelas retina pada klasifikasi ROP: Normal, Stage 1 dengan <i>demarcation line</i> , Stage 2 dengan <i>ridge</i> , dan Stage 3 dengan neovaskularisasi ekstremitas. Sumber: dokumentasi proyek	5
2	Kemajuan nilai Dice segmentasi pembuluh darah sepanjang proses optimasi. Konfigurasi terbaik <i>g40_m60_fine</i> mencapai Dice = 0,4739	10
3	Kerangka <i>pipeline</i> penelitian yang menunjukkan lima skenario input dan alur pemrosesan menuju model <i>TinyResNetV2</i>	12
4	Arsitektur <i>TinyResNetV2</i> dengan tiga tahap <i>residual block</i> dan lebar kanal bertingkat (48/96/192). Hubungan pintas (<i>skip connection</i>) memungkinkan gradien mengalir langsung melewati setiap blok	14
5	Matriks konfusi model terbaik <i>TinyResNetV2</i> dengan masukan softmax dan evaluasi <i>group-aware 5-fold</i> pada 1.099 citra	21
6	Perbandingan <i>macro F1-score</i> seluruh konfigurasi yang dievaluasi. Bar yang disorot menunjukkan model terbaik	22

DAFTAR LAMPIRAN

1	Lampiran 1 Konfigurasi <i>Hyperparameter</i> Model TinyResNetV2	29
2	Lampiran 2 Konfigurasi Pipeline Segmentasi Pembuluh Darah Terbaik	30
3	Lampiran 3 Distribusi Lengkap Dataset Zhao2024	31

I PENDAHULUAN

1.1 Latar Belakang

Retinopathy of Prematurity (ROP) adalah gangguan pembuluh darah retina yang terjadi pada bayi yang lahir sebelum waktunya. Kondisi ini muncul akibat pertumbuhan pembuluh darah retina yang tidak sempurna setelah kelahiran prematur, dan dapat berkembang menjadi ablasio retina yang menyebabkan kebutaan permanen jika tidak ditangani sejak awal (Chiang et al. 2021; Vahidmoghadam et al. 2026). Kemajuan di bidang perawatan neonatal telah meningkatkan angka kelangsungan hidup bayi prematur di seluruh dunia, sehingga jumlah kasus ROP yang memerlukan pemantauan juga meningkat secara signifikan.

Secara klinis, keparahan ROP dibagi ke dalam beberapa *stage* berdasarkan perubahan struktural yang terlihat pada retina melalui pemeriksaan fundus. *Stage 1* ditandai dengan adanya garis batas (*demarcation line*) yang memisahkan area retina yang sudah dan belum memiliki pembuluh darah. *Stage 2* menunjukkan penebalan garis tersebut menjadi tonjolan jaringan (*ridge*). Pada *stage 3*, terjadi pertumbuhan pembuluh darah baru ke arah vitreous yang disebut neovaskularisasi ekstrasretina (Chiang et al. 2021). Diagnosis yang tepat pada *stage* awal sangat penting karena intervensi medis yang tepat waktu dapat mencegah perkembangan ke kondisi yang lebih parah.

Diagnosis ROP saat ini bergantung pada pemeriksaan langsung oleh dokter spesialis mata menggunakan kamera fundus khusus. Tantangan utama dalam proses ini adalah kelangkaan dokter spesialis retina anak, terutama di negara berkembang, serta tingginya variabilitas antar-dokter dalam menilai *stage* penyakit (Tong et al. 2020). Otomatisasi melalui *computer vision* menawarkan potensi untuk membantu proses skrining massal dan mengurangi beban tenaga medis.

Namun, klasifikasi otomatis *stage* ROP menghadapi tantangan tersendiri. Citra fundus bayi memiliki kualitas yang lebih rendah dibanding citra fundus dewasa karena adanya refleksi kornea, pupil yang lebih kecil, dan kesulitan dalam mempertahankan fiksasi pandangan bayi selama pengambilan gambar. Selain itu, perbedaan visual antar-*stage*, khususnya antara *Stage 1* dan *Stage 2*, sangat halus sehingga bahkan model jaringan saraf yang telah dilatih dengan data besar pun sering kesulitan membedakan keduanya (Zhao et al. 2024).

Penelitian sebelumnya menunjukkan bahwa teknik *enhancement* citra seperti *contrast-limited adaptive histogram equalization* (CLAHE) dan koreksi pencahayaan dapat membantu menonjolkan struktur klinis penting pada citra fundus bayi (Rahim et al. 2024). Demikian pula, segmentasi pembuluh darah secara otomatis telah terbukti dapat menghasilkan peta spasial yang berguna sebagai panduan bagi model klasifikasi (Almeida et al. 2024). Namun, pengaruh masing-masing pendekatan terhadap performa klasifikasi *stage* ROP secara spesifik belum banyak diteliti secara sistematis dan terkontrol.

Penelitian ini dirancang untuk menjawab pertanyaan tersebut secara langsung melalui sebuah *pipeline* yang membandingkan berbagai bentuk representasi citra—mulai dari piksel RGB mentah, citra hasil *enhancement*, hingga peta pembuluh darah—sebagai masukan untuk model jaringan saraf yang sama. Penelitian ini juga menyelidiki apakah sebuah jaringan saraf kecil yang dilatih dari awal (*from scratch*)

tanpa bobot pra-latih dapat mencapai performa yang bersaing dengan pendekatan berbasis fitur klasik.

1.2 Rumusan Masalah

Penelitian ini berfokus pada tiga pertanyaan teknis utama:

Apakah *enhancement* citra meningkatkan akurasi klasifikasi? Koreksi pencahayaan dan CLAHE pada ruang warna $L^*a^*b^*$ diuji untuk melihat apakah perbaikan kontras citra secara visual berkorelasi dengan peningkatan performa model pada tugas klasifikasi *stage* ROP.

Apakah struktur pembuluh darah saja sudah cukup untuk membedakan *stage*? *Vessel mask* biner hasil segmentasi pembuluh darah diuji secara terpisah untuk mengukur sejauh mana informasi bentuk dan distribusi pembuluh darah dapat membantu membedakan antara *stage* 1 hingga 3 tanpa bergantung pada tekstur retina lainnya.

Apakah representasi *softmax* spasial lebih baik dari ringkasan fitur klasik? Model jaringan saraf yang menerima peta spasial (*softmax*) pembuluh darah dan area tepi secara langsung dibandingkan dengan model berbasis fitur skalar klasik yang menggunakan informasi vaskular yang sama, untuk menguji apakah pemrosesan spasial oleh jaringan saraf memberikan keuntungan yang nyata.

1.3 Tujuan

Tujuan penelitian ini adalah:

1. Membangun dan mengevaluasi *pipeline* segmentasi pembuluh darah retina secara klasik pada citra fundus bayi menggunakan kombinasi filter Gabor dan Meijering.
2. Membandingkan performa model *TinyResNetV2* dalam mengklasifikasi *stage* ROP menggunakan empat skenario representasi input: citra RGB mentah, citra hasil *enhancement*, *vessel mask* biner, dan citra *enhanced* yang dipandu *vessel mask*.
3. Menguji apakah representasi *softmax* spasial sebagai masukan model jaringan saraf dapat melampaui pendekatan berbasis fitur klasik yang menggunakan informasi vaskular yang sama.
4. Mengevaluasi dampak protokol validasi silang yang mempertimbangkan kelompok citra (*group-aware cross-validation*) terhadap keandalan estimasi performa model.

1.4 Ruang Lingkup

Batasan dan lingkup penelitian ini ditetapkan sebagai berikut:

- **Dataset Utama:** Menggunakan dataset publik Zhao2024 (Zhao et al. 2024) yang terdiri dari 1.099 citra fundus bayi dalam lima kelas untuk eksperimen klasifikasi utama.

- **Kelas Klasifikasi:** Mencakup Normal, Stage 1, Stage 2, Stage 3, dan *laser scars*. Kelas *laser scars* dimasukkan dalam klasifikasi akhir untuk mendekati pengaturan 5-kelas yang digunakan dalam publikasi Zhao2024.
- **Dataset Sekunder:** Menggunakan bagian HVDROPDB-BV dari Agrawal2021 (Agrawal et al. 2021) khusus untuk mengevaluasi kualitas segmentasi pembuluh darah secara kuantitatif menggunakan metrik Dice.
- **Model:** Menggunakan arsitektur *custom TinyResNetV2* yang dilatih dari awal tanpa bobot pra-latih. Tidak ada penggunaan model pra-latih pada *dataset* seperti ImageNet dalam penelitian ini.
- **Konteks:** Penelitian ini bersifat akademis dan bukan merupakan sistem diagnostik klinis. Hasil yang dilaporkan tidak boleh digunakan untuk pengambilan keputusan medis.

1.5 Manfaat Penelitian

Penelitian ini memberikan beberapa kontribusi yang dapat digunakan oleh peneliti dan pengembang sistem di bidang analisis citra medis:

- Menunjukkan secara eksperimental bahwa representasi spasial dari informasi pembuluh darah lebih efektif daripada ringkasan fitur skalar dalam tugas klasifikasi *stage* ROP.
- Memberikan bukti empiris tentang pentingnya protokol validasi silang yang mempertimbangkan kelompok citra serupa (*group-aware*) agar estimasi performa yang dilaporkan mencerminkan kemampuan generalisasi model secara realistis.
- Mendokumentasikan pengembangan sistematis *pipeline* segmentasi pembuluh darah klasik melalui serangkaian konfigurasi yang dievaluasi secara terkontrol.
- Menyediakan kerangka percobaan yang dapat direplikasi untuk penelitian lanjutan tentang klasifikasi *stage* ROP dengan data yang lebih besar atau arsitektur yang lebih canggih.

II TINJAUAN PUSTAKA


2.1 Retinopathy of Prematurity dan Tahapannya

Retinopathy of Prematurity (ROP) adalah kelainan pembuluh darah retina yang terjadi pada bayi yang lahir sebelum waktunya, terutama yang lahir sebelum usia kehamilan 31 minggu atau dengan berat badan lahir di bawah 1.500 gram. Kondisi ini terjadi karena pembuluh darah retina yang belum sempat terbentuk secara lengkap di dalam kandungan kemudian tumbuh secara tidak normal setelah kelahiran, sebagai respons terhadap kadar oksigen yang berubah dan faktor pertumbuhan yang tidak seimbang (Chiang et al. 2021).

Berdasarkan Klasifikasi Internasional ROP (*International Classification of Retinopathy of Prematurity*, ICROP) yang diperbarui pada tahun 2021 (Chiang et al. 2021), keparahan ROP dibagi ke dalam lima *stage*:

- **Normal:** Pembuluh darah retina berkembang secara teratur dari area *optic disc* ke arah pinggiran retina.
- **Stage 1:** Terdapat garis batas datar (*demarcation line*) yang memisahkan retina yang sudah berpembuluh darah dari yang belum.
- **Stage 2:** Garis batas tersebut menebal dan terangkat membentuk tonjolan jaringan (*ridge*).
- **Stage 3:** Terjadi pertumbuhan pembuluh darah baru ke arah vitreous di atas *ridge* (neovaskularisasi ekstraintina).
- **Stage 4–5:** Ablasio retina sebagian atau menyeluruh (tidak tercakup dalam penelitian ini).

Selain itu, dikenal juga kondisi *plus disease* yang ditandai oleh dilatasi dan tortuositas pembuluh darah di kutub posterior retina, yang dapat menyertai *stage* manapun dan menandakan penyakit yang lebih aktif (Chiang et al. 2021). Perbedaan visual antar *stage* awal, khususnya antara *Stage 1* dan *Stage 2*, sangat halus sehingga membutuhkan keahlian khusus dan pengalaman klinis yang tinggi (Vahidmoghadam et al. 2026). Ilustrasi setiap *stage* ditunjukkan pada Gambar 1.



Gambar 1 Empat kategori kelas retina pada klasifikasi ROP: Normal, Stage 1 dengan *demarcation line*, Stage 2 dengan *ridge*, dan Stage 3 dengan neovaskularisasi ekstraretina. Sumber: dokumentasi proyek

2.2 Dataset Citra Fundus ROP

Kemajuan dalam klasifikasi ROP berbasis komputer sangat bergantung pada ketersediaan dataset citra yang berlabel dan berkualitas baik. Zhao et al. (2024) menerbitkan dataset citra fundus ROP pertama yang bersifat publik dengan skala besar, yang terdiri dari 1.099 citra fundus bayi prematur yang dikumpulkan dari rumah sakit di Tiongkok menggunakan kamera RetCam. Dataset ini mencakup lima kategori: Normal (236 citra), Stage 1 (94 citra), Stage 2 (165 citra), Stage 3 (261 citra), dan bekas luka laser (343 citra). Setiap citra dilengkapi dengan label *stage* yang ditentukan oleh dokter spesialis mata berpengalaman. Dataset ini juga disertai dengan model *benchmark* berbasis ResNet50 pra-latih yang mencapai *macro F1-score* sebesar 0,8281 pada pengaturan 5-kelas (Zhao et al. 2024).

Dataset sekunder yang digunakan dalam penelitian ini adalah HVDROPDB dari Agrawal et al. (2021), khususnya bagian HVDROPDB-BV yang menyediakan 100 pasang citra fundus bayi beserta masker pembuluh darah yang dianotasi secara manual. Dataset ini mencakup 50 citra dari kamera RetCam dan 50 citra dari kamera Neo, sehingga mencerminkan variasi perangkat pengambilan gambar yang umum digunakan dalam skrining ROP.

2.3 Praproses dan *Enhancement* Citra Fundus

Kualitas citra fundus bayi umumnya lebih rendah dibanding citra fundus orang dewasa karena berbagai faktor teknis dan kondisi pasien. Pencahayaan yang tidak merata, refleksi kornea yang kuat, dan kontras yang rendah antara pembuluh darah dan jaringan sekitarnya merupakan tantangan utama yang perlu ditangani sebelum proses analisis otomatis (Rahim et al. 2024).

Rahim et al. (2024) menunjukkan bahwa kombinasi koreksi pencahayaan adaptif dan CLAHE pada ruang warna $L^*a^*b^*$ secara signifikan meningkatkan visibilitas struktur klinis penting seperti *demarcation line* dan *ridge*. CLAHE bekerja dengan membagi citra menjadi blok-blok kecil dan menerapkan pemerataan histogram secara terpisah pada setiap blok, dengan pembatasan klipting (*clip limit*) untuk mencegah penguatan berlebihan pada area homogen. Penggunaan ruang warna $L^*a^*b^*$ memungkinkan *enhancement* diterapkan hanya pada komponen kecerahan (L^*) tanpa mengubah informasi warna (a^* dan b^*) (Rahim et al. 2024).

Normalisasi latar belakang dengan filter Gaussian berskala besar juga merupakan teknik yang efektif untuk mengurangi ketimpangan pencahayaan. Dengan memperkirakan distribusi pencahayaan menggunakan filter Gaussian berukuran besar, kemudian membaginya dengan distribusi tersebut, variasi kecerahan antar area citra dapat dikurangi secara substansial tanpa merusak informasi detail lokal (Almeida et al. 2024).

2.4 Segmentasi Pembuluh Darah Retina

Segmentasi pembuluh darah retina secara otomatis adalah langkah praproses yang penting dalam analisis citra fundus untuk berbagai penyakit, termasuk ROP. Pembuluh darah retina memiliki karakteristik geometris yang khas, yaitu struktur *tubular* dengan intensitas yang lebih rendah dibanding jaringan sekitarnya pada kanal hijau citra RGB.

2.4.1 Metode Berbasis Filter Spasial

Pendekatan berbasis filter spasial memanfaatkan karakteristik geometris pembuluh darah untuk membedakannya dari latar belakang. Filter Gabor multi-skala dan multiorientasi terbukti efektif dalam mendeteksi struktur tubular pada berbagai orientasi. Filter ini merespons secara kuat terhadap tepi berarah yang merupakan ciri khas pembuluh darah retina (Khandouzi et al. 2022).

Filter berbasis matriks Hessian, seperti filter Frangi, Sato, dan Meijering, memanfaatkan nilai eigen dari matriks Hessian orde dua untuk mengukur derajat *vesselness* pada setiap piksel. Filter Meijering, yang dikembangkan oleh Meijering et al. (2004) untuk pelacakan filamen neurit dalam citra fluoresensi, dirancang khusus untuk mendeteksi struktur filamen tipis dan terbukti bekerja lebih baik pada pembuluh darah yang halus dibanding filter Frangi (Tian et al. 2021). Almeida et al. (2024) menunjukkan bahwa kombinasi filter berbasis Hessian dengan teknik *top-hat* morfologis mampu menghasilkan peta *vesselness* dengan respons yang kuat pada struktur tubular tanpa memicu terlalu banyak deteksi palsu.

2.4.2 Pendekatan Fusi Multi-Detektor

Penelitian terbaru menunjukkan bahwa menggabungkan respons dari beberapa jenis detektor dapat meningkatkan kualitas segmentasi secara lebih efektif daripada mengoptimalkan satu detektor saja. Filter Gabor lebih baik dalam mendeteksi pembuluh darah besar yang lebih tebal, sementara filter berbasis Hessian seperti Meijering lebih sensitif terhadap pembuluh darah kecil yang tipis. Fusi keduanya dengan pembobotan yang tepat dapat menghasilkan peta segmentasi yang mencakup rentang ukuran pembuluh darah yang lebih luas (Almeida et al. 2024).

2.5 Klasifikasi ROP Berbasis *Deep Learning*

Penggunaan jaringan saraf tiruan untuk analisis citra medis ROP telah berkembang pesat dalam beberapa tahun terakhir. Zhang et al. (2021) melakukan tinjauan sistematis dan meta-analisis terhadap 24 penelitian tentang penggunaan algoritma *deep learning* untuk mendeteksi ROP dari citra fundus, dan menemukan bahwa sebagian besar model mencapai akurasi di atas 90% untuk tugas biner (ROP vs. Normal), namun performa turun secara signifikan pada tugas klasifikasi multi-*stage*.

Tong et al. (2020) mengembangkan sistem berbasis CNN untuk identifikasi otomatis ROP dan mengujinya pada dataset klinis dari rumah sakit di Tiongkok. Model mereka mencapai sensitivitas dan spesifisitas yang tinggi untuk deteksi ROP membutuhkan terapi, namun tidak membahas secara detail performa per-*stage*.

Vahidmoghadam et al. (2026) mengusulkan pendekatan yang menggabungkan informasi citra dengan masker pembuluh darah untuk mendeteksi *plus disease* dan *stage* awal ROP secara bersamaan. Penelitian ini menunjukkan bahwa informasi vaskular yang disajikan sebagai masukan tambahan dapat meningkatkan kemampuan model dalam membedakan *stage* yang secara visual sangat mirip.

2.5.1 Jaringan Residual (*Residual Network*)

Arsitektur jaringan saraf dengan *residual connection* yang diperkenalkan oleh He et al. (2016) merupakan fondasi dari sebagian besar model *deep learning* modern. *Residual connection* memungkinkan sinyal gradien mengalir langsung dari lapisan yang lebih dalam ke lapisan yang lebih dangkal selama pelatihan, sehingga mengatasi masalah *vanishing gradient* dan memungkinkan pelatihan jaringan yang jauh lebih dalam. Untuk dataset medis berukuran kecil, varian ResNet yang lebih kecil (*tiny*) lebih sesuai karena memiliki jumlah parameter yang lebih sedikit sehingga risiko *overfitting* lebih rendah.

2.5.2 Penanganan Ketidakseimbangan Kelas

Ketidakseimbangan jumlah sampel antar kelas merupakan masalah umum dalam dataset medis. Pada dataset Zhao2024, perbandingan antara kelas terbanyak (bekas luka laser: 343 sampel) dan kelas paling sedikit (Stage 1: 94 sampel) hampir mencapai 4:1. Lin et al. (2017) mengusulkan *focal loss* sebagai alternatif *cross-entropy* standar yang secara otomatis mengurangi bobot pada sampel yang mudah diklasifikasikan sehingga pelatihan lebih berfokus pada sampel yang sulit, yang biasanya merupakan sampel dari kelas minoritas. Pendekatan berbasis ensemble seperti *Random Forest* juga mendukung mekanisme pembobotan kelas secara native (Breiman 2001).

Selain itu, pemberian bobot kelas berbanding terbalik dengan frekuensinya

(*inverse frequency weighting*) merupakan teknik sederhana namun efektif untuk mengatasi ketidakseimbangan kelas (Lin et al. 2017). Teknik ini memastikan bahwa kesalahan pada kelas minoritas mendapat penalti yang lebih besar selama pelatihan.

2.5.3 Validasi Silang yang Sadar Kelompok (*Group-Aware Cross-Validation*)

Estimasi performa model yang andal membutuhkan protokol validasi yang tepat. Pada dataset citra medis, satu pasien atau satu mata dapat menghasilkan banyak citra yang sangat mirip. Apabila data dibagi secara acak pada tingkat citra, citra dari mata yang sama berpotensi masuk ke sisi pelatihan sekaligus sisi pengujian, sehingga model dapat mengenali identitas pasien alih-alih mempelajari fitur penyakit dan estimasi performa menjadi terlalu optimis. *Group-aware cross-validation* (*GroupKFold*) mengatasi risiko ini dengan memastikan seluruh citra dari kelompok yang sama selalu berada di sisi yang sama selama validasi silang, sehingga performa yang dilaporkan mencerminkan kemampuan generalisasi model terhadap pasien yang benar-benar belum pernah dilihat (Zhao et al. 2024).

III METODE

3.1 Data dan Strategi Pembagian Data

3.1.1 Dataset Utama: Zhao2024

Dataset utama yang digunakan dalam penelitian ini adalah koleksi citra fundus bayi yang diterbitkan oleh Zhao et al. (2024), selanjutnya disebut Zhao2024. Dataset ini terdiri dari 1.099 citra fundus bayi prematur dalam lima kelas: Normal, Stage 1, Stage 2, Stage 3, dan bekas luka laser (*laser scars*). Rincian distribusi kelas ditunjukkan pada Tabel 1.

Tabel 1 Distribusi kelas pada dataset Zhao2024

Kelas	Jumlah Citra
Normal	236
Stage 1	94
Stage 2	165
Stage 3	261
Laser Scars	343
Total	1.099

Analisis mendalam terhadap dataset menemukan adanya 12 citra yang identik secara byte (*byte-identical duplicates*) dalam 6 kelompok duplikat. Yang lebih penting, tiga dari kelompok tersebut merupakan konflik label antar-kelas: citra yang persis sama tercatat di bawah dua kelas yang berbeda. Pasangan yang teridentifikasi adalah *Stage_2_ROP_154.jpg* $\equiv$ *Stage_3_ROP_210.jpg*, *Stage_2_ROP_52.jpg* $\equiv$ *Stage_3_ROP_254.jpg*, dan *Stage_1_ROP_42.jpg* $\equiv$ *Stage_2_ROP_4.jpg*. Duplikat ini dibiarkan ada dalam dataset dan ditangani melalui protokol pengelompokan (*grouping*), bukan dengan menghapus data.

3.1.2 Dataset Sekunder: Agrawal2021

Dataset sekunder yang digunakan adalah bagian HVDROPDB-BV dari dataset yang diterbitkan oleh Agrawal et al. (2021). Dataset ini terdiri dari 100 pasang citra fundus bayi beserta masker pembuluh darah yang dianotasi oleh pakar, yang terbagi atas 50 citra dari kamera RetCam dan 50 citra dari kamera Neo. Dataset ini digunakan semata-mata untuk mengevaluasi kualitas pipeline segmentasi pembuluh darah secara kuantitatif menggunakan metrik Dice dan tidak terlibat dalam pelatihan atau pengujian model klasifikasi.

3.1.3 Strategi Pembagian Data dan Pengelompokan


Karena dataset Zhao2024 tidak menyediakan identitas pasien pada nama file, pembagian data secara langsung berbasis identitas pasien tidak dapat dilakukan. Sebagai solusi, analisis kemiripan antar citra menggunakan korelasi silang ternormalisasi (*Normalized Cross-Correlation*, $NCC \geq 0,99$) dilakukan untuk mendeteksi pasangan citra yang berasal dari mata yang sama. Proses ini menghasilkan 721 kelompok dari total 1.099 citra yang kemudian disimpan dalam berkas *clean_manifest.json*.

Validasi silang *5-fold* menggunakan *StratifiedGroupKFold* diterapkan agar

setiap kelompok selalu berada sepenuhnya di satu sisi batas pelatihan–pengujian. Strategi ini memastikan bahwa model benar-benar mempelajari pola penyakit, bukan pola citra dari mata tertentu.

3.2 Pipeline Segmentasi Pembuluh Darah

Pipeline segmentasi pembuluh darah dirancang berdasarkan prinsip detektor berbasis filter klasik tanpa komponen *deep learning*. Pipeline ini dioptimalkan melalui serangkaian percobaan terkontrol menggunakan dataset HVDROPDB-BV, dengan evaluasi menggunakan nilai Dice pada set pengujian yang terpisah (40% dari 100 citra). Gambar 2 menunjukkan kemajuan nilai Dice sepanjang proses optimasi.



Gambar 2 Kemajuan nilai Dice segmentasi pembuluh darah sepanjang proses optimasi. Konfigurasi terbaik *g40_m60_fine* mencapai Dice = 0,4739

3.2.1 Konfigurasi Optimal: *g40_m60_fine*

Hasil terbaik dicapai melalui fusi dua detektor dengan formula:

$$\text{softmax} = 0,40 \times \text{gabor_tophat} + 0,60 \times \text{meijering_fine} \quad (\text{III.1})$$

Langkah-langkah pemrosesan adalah sebagai berikut:

1. **Praproses kanal hijau:** Kanal hijau diekstrak dari citra RGB. Pixel di luar area *field of view* (FOV) diisi menggunakan nilai pixel FOV terdekat untuk mencegah artefak pada tahap filtering berikutnya.

2. **Normalisasi latar belakang:** Latar belakang diperkirakan menggunakan filter Gaussian berskala besar ($\sigma \approx 30$ piksel). Kanal hijau dibagi dengan perkiraan latar belakang tersebut untuk meratakan pencahayaan.
3. **CLAHE pertama:** CLAHE dengan *clip limit* 6,0 dan ukuran *tile* 16×16 diterapkan pada kanal hijau yang sudah dinormalisasi.
4. **Preprocessing top-hat:** Filter *top-hat* morfologis diterapkan pada kanal yang sudah diproses untuk mempertajam struktur pembuluh darah gelap sebelum filtering Gabor.
5. **Filter Gabor multiskala:** Bank filter Gabor multiskala (sigma: 1,5; 2,5; 3,5; 5,0 piksel) dan multiorientasi (15 sudut dari 0 hingga 165) diterapkan. Respons maksimum dari seluruh konfigurasi diambil sebagai peta respons Gabor.
6. **Penghalusan dan CLAHE kedua:** Median blur 7×7 diterapkan untuk mengurangi *noise*, diikuti CLAHE kedua (*clip limit* 12,0, *tile* 12×12). Peta gabor_tophat diperoleh dari tahap ini.
7. **Filter Meijering:** Filter Meijering dengan sigma halus (0,8; 1,4; 2,0; 2,8; 3,6; 4,5 piksel) diterapkan secara terpisah untuk mendeteksi pembuluh darah yang lebih tipis yang terlewat oleh filter Gabor.
8. **Fusi dan ambang batas:** Softmap akhir dihitung menggunakan persamaan III.1. Binarisasi menggunakan ambang persentil P0,16 dengan erosi area FOV, diikuti pemilihan tiga komponen terhubung terbesar dan penutupan morfologis (3×3).


Proses optimasi ini dimulai dari nilai Dice dasar 0,4469 (konfigurasi awal) dan mencapai nilai Dice 0,4739 pada iterasi ketujuh. Ringkasan kemajuan ditunjukkan pada Tabel 2.

Tabel 2 Ringkasan kemajuan nilai Dice segmentasi pembuluh darah

Iterasi	Perubahan Utama	Dice (Test)	Δ vs Baseline
Baseline	Gabor + $2 \times$ CLAHE + P0,16	0,4469	—
1	Optimasi ambang batas dan <i>cleanup</i>	0,4505	+0,0036
2	Preprocessing top-hat sebelum Gabor	0,4600	+0,0131
3	Penyesuaian rasio blend top-hat	0,4599	(stabil)
4	Fusi Sato + Gabor	0,4655	+0,0186
5	Sigma Sato yang lebih halus	0,4667	+0,0198
6	Tiga cara fusi (Meijering mengganti Sato)	—	(redudansi)
7	Fusi Gabor + Meijering (terbaik)	0,4739	+0,0270
8	Konfigurasi tambahan di luar iterasi 7	(regresi)	—

3.3 Skenario Representasi Input

Penelitian ini membandingkan lima skenario representasi input untuk menguji pengaruh berbagai bentuk pemrosesan citra terhadap performa model klasifikasi. Gambar 3 menunjukkan kerangka umum pipeline penelitian.



Gambar 3 Kerangka *pipeline* penelitian yang menunjukkan lima skenario input dan alur pemrosesan menuju model *TinyResNetV2*

S1: RGB Mentah (*Raw RGB*) Citra fundus asli yang hanya diubah ukurannya menjadi 224×224 piksel dan dinormalisasi nilai pikselnya ke rentang $[0, 1]$. Skenario ini berfungsi sebagai *baseline* mutlak tanpa pemrosesan tambahan apapun.

S2: RGB Enhanced (*CLAHE*) Citra yang sudah diproses menggunakan koreksi pencahayaan berbasis normalisasi Gaussian, diikuti CLAHE pada kanal kecerahan dalam ruang warna CIE $L^*a^*b^*$. Skenario ini menguji apakah peningkatan kontras secara visual berkontribusi pada performa klasifikasi.

S3: Vessel Mask Citra biner satu kanal yang berisi hasil segmentasi pembuluh darah. Direplikasi menjadi tiga kanal untuk memenuhi spesifikasi input model. Skenario ini menguji apakah informasi bentuk dan distribusi pembuluh darah saja—tanpa tekstur retina lainnya—sudah cukup informatif.

S4: Vessel-Guided Enhanced Citra S2 yang dikalikan secara piksel dengan peta probabilitas halus (*soft vesselness map*) turunan dari S3, sehingga area di sekitar pembuluh darah mendapat penekanan lebih kuat. Skenario ini menguji apakah

penekanan konteks vaskular membantu model memfokuskan perhatiannya pada area yang relevan.

S5: Masked Softmap (Terbaik) Masukan tiga kanal yang dibentuk oleh: (1) *softmap* pembuluh darah dari konfigurasi *g40_m60_fine*, (2) *softmap* area tepi (*ridge softmap*), dan (3) kanal hijau ternormalisasi CLAHE yang telah di-masker FOV. Semua kanal bersifat kontinu (bukan biner) dan dimasker oleh FOV. Skenario ini menghasilkan performa terbaik di antara seluruh skenario yang diuji.

3.4 Baseline Klasik: Fitur Rekayasa Manual

Sebelum membangun model jaringan saraf, sebuah *baseline* berbasis fitur rekayasa manual (*handcrafted features*) dibangun untuk menetapkan batas bawah performa yang harus dilampaui. Baseline ini menggunakan 48 fitur yang diekstrak dari setiap citra, mencakup:

- **Fitur morfologi pembuluh darah:** Kerapatan pembuluh darah (*vessel density*), proksi tortuositas, anisotropi pembuluh, ukuran dan standar deviasi komponen.
- **Fitur tekstur:** Matriks kookurensi tingkat keabuan (*Gray-Level Co-occurrence Matrix*, GLCM) (Khandouzi et al. 2022) yang menghasilkan fitur kontras, korelasi, energi, dan homogenitas.
- **Fitur statistik intensitas:** Rerata dan standar deviasi intensitas pada setiap kanal warna.
- **Fitur area tepi (*ridge*):** Luas, panjang, kerapatan, dan persentil respons dari komponen *ridge* yang terdeteksi.

Fitur-fitur tersebut kemudian dimasukkan ke dalam tiga jenis model klasifikasi: *Support Vector Machine* (SVM) dengan kernel RBF, *Random Forest* (Breiman 2001) dengan 400 pohon keputusan (*n_estimators=400*, *max_depth=None*), dan *Gradient Boosting*. Evaluasi dilakukan menggunakan validasi silang *5-fold* yang distratifikasi berdasarkan kelas.

3.5 Arsitektur Model Klasifikasi: TinyResNetV2


Model klasifikasi utama adalah *TinyResNetV2*, sebuah jaringan saraf residual kecil yang dirancang dari awal (*from scratch*) tanpa menggunakan bobot pra-latih. Arsitektur ini dipilih karena ukurannya yang proporsional dengan skala dataset sehingga risiko *overfitting* dapat dikendalikan.

Arsitektur *TinyResNetV2* terdiri dari:

1. Lapisan konvolusi awal 3×3 diikuti *batch normalization* dan fungsi aktivasi ReLU.
2. Tiga tahap *residual block* bertingkat dengan lebar fitur masing-masing 48, 96, dan 192 kanal. Setiap tahap menerapkan *downsampling* spasial melalui konvolusi dengan *stride* 2.

3. *Global Average Pooling* untuk meringkas peta fitur dua dimensi menjadi vektor satu dimensi.
4. Lapisan *Dropout* untuk regulasi.
5. Lapisan *Dense* dengan fungsi aktivasi *softmax* untuk lima kelas.

Struktur *residual block* mengikuti pola dasarnya: *conv-BN-ReLU-conv-BN* dengan hubungan pintas (*skip connection*) yang menjumlahkan masukan blok dengan keluarannya. Arsitektur ini ditunjukkan pada Gambar 4.



Gambar 4 Arsitektur *TinyResNetV2* dengan tiga tahap *residual block* dan lebar kanal bertingkat (48/96/192). Hubungan pintas (*skip connection*) memungkinkan gradien mengalir langsung melewati setiap blok

3.6 Protokol Pelatihan

3.6.1 Fungsi Kerugian dan Pembobotan Kelas

Pelatihan menggunakan *focal loss* (Lin et al. 2017) dengan parameter $\gamma = 1,0$ dan bobot kelas berbanding terbalik dengan frekuensi masing-masing kelas (*inverse-frequency class weights*). *Focal loss* secara otomatis mengurangi kontribusi sampel yang mudah diklasifikasikan, sehingga pelatihan lebih berfokus pada sampel kelas minoritas yang sulit.

3.6.2 Optimisasi dan Penjadwalan Laju Belajar

Optimisasi menggunakan algoritma AdamW (Loshchilov dan Hutter 2019) dengan laju belajar awal 10^{-3} dan peluruhan bobot (*weight decay*) 5×10^{-4} . Laju belajar dijadwalkan menggunakan strategi *cosine annealing* selama 160 *epoch*.

3.6.3 Augmentasi Data

Augmentasi data diterapkan selama pelatihan untuk meningkatkan variasi data latih dan mengurangi *overfitting*. Teknik augmentasi yang digunakan meliputi:

- *MixUp* (Zhang et al. 2018) ($\alpha = 0,2$, probabilitas 0,5 per *batch*): menggabungkan dua sampel dan labelnya secara linear.
- *CutMix* (Yun et al. 2019) ($\alpha = 1,0$, probabilitas 0,5 per *batch*): menempelkan potongan gambar dari satu sampel ke sampel lain dengan label proporsional.
- *Label smoothing* 0,1: meratakan distribusi target agar model tidak terlalu percaya diri (*overconfident*) pada satu kelas.
- *Stochastic depth (DropPath)* (Huang et al. 2016) dengan jadwal linear $0 \rightarrow 0,2$: menonaktifkan sebagian jalur residual secara acak selama pelatihan sebagai bentuk regulasi.
- *Weight EMA (Exponential Moving Average)* dengan peluruhan 0,999: meratakan bobot model secara eksponensial untuk mendapatkan model yang lebih stabil.
- *Flip test-time augmentation* pada saat inferensi OOF: prediksi dirata-ratakan dari citra asli dan cerminan horizontalnya.

3.6.4 Protokol Validasi Silang

Protokol utama yang digunakan adalah *StratifiedGroupKFold* dengan 5 *fold*. Pembagian ini memastikan bahwa: (1) distribusi kelas pada setiap *fold* kira-kira proporsional, dan (2) seluruh citra dari kelompok yang sama (kelompok citra serupa yang terdeteksi melalui NCC) selalu berada di sisi yang sama. Prediksi *out-of-fold* (OOF) dari kelima fold digabungkan untuk menghitung metrik evaluasi akhir.

3.7 Metrik Evaluasi

3.7.1 Metrik Klasifikasi

Metrik utama yang digunakan adalah *macro F1-score*, yaitu rata-rata dari nilai F1-score masing-masing kelas tanpa memperhitungkan jumlah sampel per kelas. Metrik ini dipilih karena ketidakseimbangan kelas pada dataset membuat akurasi keseluruhan tidak cukup informatif; kelas dengan sampel lebih banyak dapat mendominasi akurasi meskipun kelas minoritas berkinerja buruk. Formula *macro F1-score* adalah:

$$\text{Macro F1} = \frac{1}{K} \sum_{k=1}^K F1_k = \frac{1}{K} \sum_{k=1}^K \frac{2 \cdot P_k \cdot R_k}{P_k + R_k} \quad (\text{III.2})$$

di mana K adalah jumlah kelas, P_k adalah presisi, dan R_k adalah *recall* untuk kelas ke- k .

Selain *macro F1-score*, metrik tambahan yang dilaporkan mencakup akurasi keseluruhan, *macro precision*, *macro recall*, dan F1-score per kelas.

3.7.2 Metrik Segmentasi

Kualitas segmentasi pembuluh darah dievaluasi menggunakan *Dice coefficient* (Sørensen 1948), yang mengukur tumpang tindih antara masker prediksi dan masker *ground truth* dari anotasi pakar. Formula *Dice coefficient* adalah:

$$\text{Dice} = \frac{2 \times |A \cap B|}{|A| + |B|} \quad (\text{III.3})$$

di mana A adalah masker prediksi dan B adalah masker *ground truth*. Evaluasi dilakukan pada 40 citra set pengujian yang tidak pernah terlihat selama optimasi pipeline.

IV HASIL DAN PEMBAHASAN

4.1 Hasil Segmentasi Pembuluh Darah

4.1.1 Kemajuan Optimasi Pipeline

Optimasi pipeline segmentasi pembuluh darah dilakukan melalui serangkaian percobaan ablasi yang sistematis. Konfigurasi dasar (*baseline*) menggunakan filter Gabor standar dengan dua tahap CLAHE, menghasilkan nilai Dice 0,4469 pada set pengujian. Setiap percobaan berikutnya menguji satu perubahan utama terhadap pipeline, sehingga kontribusi masing-masing komponen dapat diidentifikasi secara terpisah.

Dua faktor utama memberikan peningkatan terbesar terhadap nilai Dice:

- **Preprocessing top-hat:** Penambahan filter *top-hat* morfologis sebelum filter Gabor memberikan peningkatan Dice sebesar +0,0131 (dari 0,4469 menjadi 0,4600). Filter *top-hat* mempertajam struktur gelap pembuluh darah terhadap latar belakang sebelum filter Gabor bekerja, sehingga respons Gabor terhadap pembuluh darah menjadi lebih kuat.
- **Fusi Gabor + Meijering:** Penggantian detektor tunggal dengan fusi dua detektor—Gabor untuk pembuluh besar dan Meijering untuk pembuluh tipis—memberikan peningkatan tambahan sebesar +0,0139 hingga mencapai nilai Dice akhir 0,4739. Ini adalah nilai Dice tertinggi yang dicapai dalam seluruh proses optimasi.

Konfigurasi terbaik *g40_m60_fine* dengan formula $0,40 \times \text{gabor_tophat} + 0,60 \times \text{meijering_fine}$ kemudian dijadikan sebagai sumber kanal pembuluh darah dalam skenario masukan S5.

4.1.2 Temuan Penting: Dice Segmentasi $\neq$ Performa Klasifikasi

Sebuah temuan penting yang diperoleh selama proses penelitian adalah bahwa memaksimalkan nilai Dice segmentasi pembuluh darah tidak secara otomatis meningkatkan performa klasifikasi *stage*. Ketika konfigurasi Dice-optimal (*g40_m60_fine*, Dice = 0,4739) digunakan sebagai masukan CNN pada percobaan awal, performa model justru turun dibanding menggunakan peta Gabor sederhana tanpa fusi Meijering. Penurunan terbesar terlihat pada Stage 3, dengan F1 turun dari 0,85 menjadi 0,79.

Hal ini karena fusi Meijering yang dirancang untuk memaksimalkan tumpang tindih dengan masker pembuluh darah sebenarnya menghaluskan peta spasial yang memuat informasi khas setiap *stage*, khususnya tekstur tepi yang membedakan Stage 2 dari Stage 3. Temuan ini menunjukkan bahwa optimasi segmentasi dan optimasi klasifikasi adalah dua tugas yang berbeda dan tidak bisa diasumsikan searah.

4.2 Hasil Baseline Klasik

4.2.1 Perbandingan Antar Pengklasifikasi

Baseline klasik menggunakan 48 fitur rekayasa manual dari peta pembuluh darah dan area tepi. Evaluasi dilakukan menggunakan validasi silang *5-fold* yang

distratifikasi pada 756 citra (kelas Stage 1, Stage 2, Stage 3 dari Zhao2024). Hasil perbandingan antar pengklasifikasi ditunjukkan pada Tabel 3.

Tabel 3 Perbandingan *macro F1-score* antar pengklasifikasi pada baseline klasik (3 kelas: Stage 1, Stage 2, Stage 3)

Pengklasifikasi	Macro F1
SVM (kernel RBF)	0,4964
Random Forest	0,5147
Gradient Boosting	0,4912
Baseline hanya fitur pembuluh darah	0,4740

Random Forest menghasilkan *macro F1-score* terbaik sebesar 0,5147 dengan konfigurasi 400 pohon keputusan dan bobot kelas seimbang. Penambahan 12 fitur area tepi (*ridge*) ke dalam 36 fitur pembuluh darah memberikan peningkatan nyata sebesar +0,041 (dari 0,474 menjadi 0,5147).

4.2.2 Pentingnya Fitur Area Tepi

Analisis tingkat kepentingan fitur (*feature importance*) pada model *Random Forest* menunjukkan bahwa empat fitur area tepi masuk ke dalam 12 besar fitur terpenting, seperti ditunjukkan pada Tabel 4.

Tabel 4 Dua belas fitur terpenting pada model *Random Forest*

Fitur	Tingkat Kepentingan
tortuosity_proxy	0,0427
comp_size_std	0,0328
vessel_anisotropy	0,0325
int_r_std	0,0286
ridge_main_area	0,0283
ridge_main_len	0,0274
ridge_main_extent	0,0267
soft_std	0,0266
comp_size_max	0,0260
glcm_correlation_std	0,0258
ridge_resp_p95	0,0247
vessel_density	0,0243

Nilai-nilai ini mengonfirmasi bahwa fitur area tepi (*ridge*) memberikan kontribusi nyata dalam membedakan *stage* ROP, khususnya antara Stage 2 (yang ditandai *ridge*) dan Stage lainnya.

4.2.3 Batas Atas Performa Klasik: Hambatan Stage 1

Meskipun penambahan fitur tepi meningkatkan performa secara keseluruhan, F1-score untuk Stage 1 hampir tidak bergerak dari rentang 0,30–0,31 pada seluruh konfigurasi yang dicoba. Analisis menunjukkan bahwa filter tepi klasik hanya mampu mendeteksi sekitar 37% piksel *demarcation line* yang sebenarnya.

Garis batas yang tipis dan berkontras rendah pada Stage 1 merupakan struktur yang paling sulit dideteksi oleh filter berbasis aturan tanpa kemampuan belajar adaptif.

4.3 Hasil Klasifikasi dengan Jaringan Saraf Tiruan

4.3.1 Ringkasan Hasil Eksperimen

Eksperimen jaringan saraf tiruan dilakukan secara bertahap, dengan setiap konfigurasi membangun di atas hasil konfigurasi sebelumnya. Tabel 5 merangkum seluruh hasil yang diperoleh. Seluruh model jaringan saraf dievaluasi menggunakan protokol *group-aware cross-validation* (*StratifiedGroupKFold 5-fold*) yang diterapkan secara konsisten sejak awal agar seluruh citra dari mata yang sama berada pada *fold* yang sama (lihat Subbab 4.3.2).

Tabel 5 Ringkasan hasil eksperimen klasifikasi

Eksperimen	Input	Macro F1	Catatan
CNN awal (raw RGB)	RGB 3-kanal	0,45	Tanpa pra-latih
Baseline klasik terbaik	48 fitur	0,5147	RF, 3 kelas
CNN RGB (group-aware)	RGB 3-kanal	0,6866	Baseline CNN
CNN softmax (group-aware)	Softmap	0,7853	Terbaik
CNN + kalibrasi Stage1	Softmap	0,8018	Kalibrasi pasca-hoc

4.3.2 Protokol Evaluasi *Group-Aware*

Pemilihan protokol evaluasi merupakan keputusan metodologis yang menentukan kredibilitas seluruh estimasi performa. Dataset ROP yang digunakan memiliki dua karakteristik yang menuntut pembagian data dilakukan pada tingkat kelompok mata, bukan pada tingkat citra individual:

1. **Duplikat byte-identik:** Terdapat 12 berkas citra yang persis sama dalam 6 kelompok, termasuk tiga pasang dengan label kelas yang berbeda (konflik label). Duplikat semacam ini dapat muncul di kedua sisi batas pelatihan–pengujian secara bersamaan.
2. **Citra satu mata:** Beberapa citra berasal dari mata yang sama tetapi dicatat sebagai berkas terpisah. Analisis *normalized cross-correlation* ($NCC \geq 0,99$) mengidentifikasi sekitar 63 pasang citra hampir-duplikat. Pembagian data pada tingkat citra akan membiarkan citra dari mata yang sama masuk ke pelatihan dan pengujian sekaligus, sehingga model dapat mengidentifikasi mata—bukan penyakitnya.

Untuk mengatasi kedua karakteristik tersebut, seluruh eksperimen klasifikasi jaringan saraf menggunakan *StratifiedGroupKFold 5-fold*, di mana seluruh citra dari satu kelompok mata ditempatkan pada *fold* yang sama. Protokol ini menghasilkan estimasi performa yang lebih jujur dan dapat dipercaya, meskipun nilainya secara absolut lebih rendah dibanding pembagian tingkat citra. Estimasi yang konservatif namun valid ini lebih bermakna secara klinis dibanding angka tinggi yang tidak dapat digeneralisasikan.

4.3.3 Hasil Terbaik: TinyResNetV2 dengan Masukan Softmap

Model dengan performa terbaik adalah *TinyResNetV2* yang dilatih dari awal menggunakan masukan tiga kanal softmap, dievaluasi dengan *StratifiedGroupKFold 5-fold*. Hasil lengkap ditunjukkan pada Tabel 6.

Tabel 6 Hasil model terbaik: *TinyResNetV2* dengan masukan softmap (group-aware CV)

Metrik	Nilai
OOF Macro F1-score	0,7853
OOF Akurasi	0,8317
OOF Macro Precision	0,7867
OOF Macro Recall	0,8028
F1 per-fold (5 fold)	0,7747 / 0,7881 / 0,7597 / 0,7834 / 0,8203


Performa per-kelas ditunjukkan pada Tabel 7.

Tabel 7 Performa per kelas model terbaik (OOF, group-aware)

Kelas	Presisi	Recall	F1	Jumlah
Normal	0,95	0,90	0,93	236
Stage 1	0,45	0,77	0,57	94
Stage 2	0,70	0,61	0,65	165
Stage 3	0,83	0,82	0,83	261
Laser Scars	1,00	0,92	0,96	343
Macro	0,79	0,80	0,79	1.099

Visualisasi matriks konfusi model terbaik ditunjukkan pada Gambar 5.

Confusion Matrix - Model Juara (TinyResNetV2, Group-Aware CV)




Gambar 5 Matriks konfusi model terbaik *TinyResNetV2* dengan masukan softmap dan evaluasi *group-aware 5-fold* pada 1.099 citra

4.4 Pembahasan

4.4.1 Peningkatan yang Dikontrol: Representasi Softmap vs. RGB

Percobaan ablasi yang paling bisa dipercaya dalam penelitian ini adalah perbandingan langsung antara masukan RGB mentah dan masukan softmap pada model, data, protokol, dan hyperparameter yang identik—satu-satunya variabel yang berbeda adalah representasi input. Hasil perbandingan ditunjukkan pada Gambar 6.



Gambar 6 Perbandingan *macro F1-score* seluruh konfigurasi yang dievaluasi. Bar yang disorot menunjukkan model terbaik

Masukan softmax menghasilkan *macro F1-score* 0,7853 dibanding 0,6866 untuk masukan RGB pada model yang sama, menunjukkan peningkatan terkontrol sebesar **+0,0987**. Peningkatan ini sepenuhnya dapat dikaitkan dengan perbedaan representasi input, karena tidak ada variabel lain yang berubah. Ini membuktikan secara langsung bahwa informasi spasial pembuluh darah dan area tepi yang dikodekan dalam softmax lebih berguna bagi jaringan saraf dibanding nilai piksel RGB mentah.

4.4.2 Hambatan pada Stage 1 dan Stage 2

Kelas Stage 1 dan Stage 2 tetap menjadi tantangan terbesar dalam klasifikasi. Stage 1 mencapai F1-score 0,57 dengan presisi rendah (0,45) namun recall tinggi (0,77), menunjukkan bahwa model cenderung terlalu sering memprediksi Stage 1. Banyak sampel Stage 2 yang diprediksi sebagai Stage 1, yang merupakan *adjacent-class confusion*—kesalahan yang dapat dipahami karena Stage 1 dan Stage 2 berbeda hanya dalam tingkat ketebalan *ridge* yang secara visual sangat mirip.

Stage 2 mencapai F1-score 0,65 dengan recall yang lebih rendah (0,61), menunjukkan sebagian sampel Stage 2 yang bocor ke Stage 1 (nilai rendah, bergabung dengan prediksi Stage 1 yang berlebih) dan Stage 3 (nilai tinggi). Pola ini konsisten dengan karakteristik penyakit: Stage 2 adalah kondisi *transisi* antara Stage

1 dan Stage 3, sehingga batas keputusannya secara alami lebih tidak jelas.

4.4.3 Pendekatan yang Tidak Efektif

Penelitian ini secara eksplisit mendokumentasikan dua pendekatan yang telah dicoba dan terbukti tidak efektif:

(1) Ordinal smoothing (v3): Hipotesis bahwa memperlakukan *stage* sebagai variabel ordinal ($\text{Stage 1} < \text{Stage 2} < \text{Stage 3}$) dengan menggunakan *ordinal neighbor smoothing* (ONSCE, $\varepsilon = 0,15$) akan mengurangi kesalahan antar-*stage* yang berdekatan. Hasilnya menunjukkan sebaliknya: pada percobaan ablasi 2×2 yang terkontrol, penambahan *ordinal smoothing* ke model v2 justru menurunkan *macro F1* sebesar 0,055. *Recall* Stage 1 yang ditarget untuk ditingkatkan justru turun dari 0,57 menjadi 0,51. Pendekatan ini dinyatakan gagal.

(2) Oversampling Stage 1: Hipotesis bahwa memperbanyak sampel Stage 1 ($n=94$) dalam setiap *batch* menggunakan *WeightedRandomSampler* dengan faktor $\times 3$ akan memperbaiki F1-score Stage 1. Hasilnya: pada dua fold yang dijalankan, performa turun dari 0,778 menjadi 0,717 dan dari 0,773 menjadi 0,684. Masalah pada Stage 1 bukan kekurangan eksposur (*recall* sudah 0,77), melainkan terlalu banyak prediksi palsu positif (*precision* hanya 0,45). Oversampling memperburuk ketidakseimbangan ini. Pendekatan ini dinyatakan gagal.

Pelajaran dari kedua kegagalan ini adalah bahwa masalah Stage 1–Stage 2 merupakan konfusi yang disebabkan oleh kesamaan visual antar kelas yang berdekatan secara klinis. Solusi yang mungkin efektif adalah pendekatan yang dapat mengurangi prediksi palsu positif Stage 1 secara spesifik, bukan pendekatan yang memperbesar sinyal Stage 1 secara global.

4.4.4 Keterbatasan Penelitian

Beberapa keterbatasan penting perlu dicatat:

- **Tidak ada identitas pasien yang terverifikasi:** Pengelompokan berdasarkan NCC merupakan pendekatan terbaik yang tersedia mengingat tidak adanya ID pasien dalam nama berkas. Meskipun ini mengurangi risiko tumpang tindih antar himpunan data, hasilnya tidak dapat dijamin setara dengan pembagian berbasis pasien yang terverifikasi.
- **Dataset tunggal:** Seluruh eksperimen dilakukan pada dataset Zhao2024 dari satu negara dan jenis kamera yang dominan. Kemampuan generalisasi ke dataset dari kamera berbeda atau populasi yang berbeda belum diuji.
- **Tidak ada bobot pra-latih:** Keputusan untuk tidak menggunakan bobot pra-latih (karena kanal masukan adalah softmap, bukan RGB) berarti penelitian ini tidak dapat memanfaatkan pengetahuan visual umum yang telah dipelajari dari dataset berskala besar. Ini adalah pertukaran (*trade-off*) yang disengaja dan terdokumentasi.
- **Batas atas Stage 1:** F1-score Stage 1 sebesar 0,57 masih jauh di bawah kelas lainnya. Meningkatkan performa Stage 1 memerlukan penelitian lebih lanjut, mungkin dengan menggunakan model segmentasi yang dapat dipelajari (*learned segmenter*) seperti U-Net (Ronneberger et al. 2015) untuk menghasilkan peta tepi yang lebih akurat.

V SIMPULAN DAN SARAN

5.1 Simpulan

Penelitian ini membangun dan mengevaluasi sebuah *pipeline* klasifikasi *stage Retinopathy of Prematurity* (ROP) dari citra fundus bayi, dengan fokus pada pengaruh berbagai bentuk representasi citra terhadap performa model jaringan saraf tiruan. Berdasarkan seluruh rangkaian eksperimen yang telah dilakukan, diperoleh tiga simpulan utama.

Pertama, representasi spasial pembuluh darah jauh lebih efektif daripada ringkasan fitur skalar. Percobaan ablasi yang terkontrol—menggunakan model, data, protokol, dan *hyperparameter* yang identik dengan satu-satunya variabel yang berbeda adalah representasi input—menunjukkan bahwa masukan *softmax* tiga kanal (peta pembuluh darah + peta area tepi + kanal hijau ternormalisasi) menghasilkan *macro F1-score* sebesar 0,7853, dibanding 0,6866 untuk masukan RGB mentah. Peningkatan terkontrol sebesar +0,0987 ini sepenuhnya dapat dikaitkan dengan kualitas representasi input, bukan perbedaan model atau protokol. Baseline klasik terbaik yang menggunakan fitur vaskular yang sama namun diringkas menjadi vektor 48 dimensi hanya mencapai 0,5147. Jaringan saraf dapat memanfaatkan struktur spasial dari informasi yang sama secara jauh lebih efektif.

Kedua, protokol validasi silang yang mempertimbangkan kelompok citra adalah syarat wajib untuk mendapatkan estimasi performa yang bisa dipercaya. Apabila pembagian data dilakukan pada tingkat citra tanpa mempertimbangkan kelompok, citra dari mata yang sama dapat masuk ke kedua sisi batas pelatihan dan pengujian, sehingga model berisiko mempelajari identitas mata alih-alih pola penyakit dan menghasilkan estimasi performa yang terlalu optimistis. Dengan menerapkan *StratifiedGroupKFold* atas 721 kelompok yang teridentifikasi, angka yang dilaporkan (0,7853) merupakan estimasi yang lebih jujur dan dapat dipertanggungjawabkan secara metodologis.

Ketiga, kompleksitas tambahan tidak selalu memberikan perbaikan. Dua pendekatan yang secara intuitif tampak menjanjikan—*ordinal smoothing* dan *oversampling*—keduanya terbukti tidak berhasil dalam penelitian ini. *Ordinal smoothing* menurunkan performa sebesar 0,055, sementara *oversampling* Stage 1 justru memperburuk masalah presisi. Model *TinyResNetV2* sederhana yang dilatih dari awal dengan *focal loss* dan kalibrasi pasca-hoc yang transparan merupakan pendekatan terbaik yang ditemukan.

5.2 Saran

Berdasarkan temuan dan keterbatasan penelitian ini, beberapa saran untuk penelitian lanjutan adalah sebagai berikut:

(1) Penggunaan segmenter yang dapat dipelajari untuk area tepi (*ridge*). Pipeline segmentasi klasik dalam penelitian ini hanya mampu mendeteksi sekitar 37% piksel *demarcation line* pada Stage 1, yang merupakan hambatan utama dalam meningkatkan F1-score Stage 1. Penggunaan model segmentasi berbasis jaringan saraf seperti U-Net (Ronneberger et al. 2015) yang dilatih secara khusus untuk mendeteksi *demarcation line* dan *ridge* dapat menghasilkan peta area tepi yang jauh lebih lengkap dan akurat, yang kemudian dapat meningkatkan performa klasifikasi

Stage 1 secara bermakna.

(2) Pengumpulan data dengan metadata pasien yang terstruktur. Penelitian ini menghadapi keterbatasan dalam validasi karena tidak tersedianya ID pasien yang terverifikasi pada dataset yang digunakan. Penelitian selanjutnya sebaiknya menggunakan dataset dengan metadata pasien yang lengkap sehingga pembagian data dapat dilakukan pada tingkat pasien, bukan pada tingkat estimasi kemiripan citra.

(3) Pengujian pada data dari berbagai jenis kamera dan kondisi klinis yang berbeda. Dataset Zhao2024 didominasi oleh citra dari satu jenis kamera dan satu negara. Kemampuan model untuk bekerja dengan baik pada citra dari kamera lain (misalnya kamera wide-field atau kamera portabel) perlu diuji secara terpisah sebelum model ini dapat dipertimbangkan untuk aplikasi skrining yang lebih luas.

(4) Eksplorasi strategi yang mengurangi prediksi palsu positif Stage 1. Hasil penelitian menunjukkan bahwa masalah utama pada Stage 1 adalah presisi yang rendah (0,45), bukan *recall* (0,77). Penelitian selanjutnya perlu mencari pendekatan yang secara spesifik mengurangi kesalahan memprediksi Stage 1 pada sampel Stage 2, misalnya dengan menggunakan mekanisme perhatian (*attention mechanism*) yang dapat memfokuskan model pada perbedaan halus antara kedua kelas tersebut.

(5) Integrasi dengan sistem skrining klinis yang lebih luas. Dalam jangka panjang, model yang dikembangkan perlu divalidasi secara klinis dalam lingkungan nyata dengan melibatkan dokter spesialis sebagai evaluator akhir. Penelitian kolaboratif antara peneliti komputer dan praktisi medis diperlukan untuk memastikan bahwa metrik yang dioptimalkan dalam penelitian benar-benar mencerminkan kebutuhan diagnosis klinis yang sesungguhnya.

DAFTAR PUSTAKA

- Agrawal R, Kulkarni S, Walambe R, Kotecha K. 2021. Assistive framework for automatic detection of all the zones in retinopathy of prematurity using deep learning. *Journal of Digital Imaging*. 34:932–947. doi:10.1007/s10278-021-00477-8.
- Almeida J, Kubicek J, Penhaker M, Cerny M, Augustynek M, Varysova A, Bansal A, Timkovic J. 2024. Enhancing ROP plus form diagnosis: an automatic blood vessel segmentation approach for newborn fundus images. *Results in Engineering*. 24:103054. doi:10.1016/j.rineng.2024.103054.
- Breiman L. 2001. Random forests. *Machine Learning*. 45(1):5–32. doi:10.1023/A:1010933404324.
- Chiang M, Quinn G, Fielder A, Ostmo S, Chan R, Barber J, Campbell J, Kalpathy-Cramer J. 2021. International classification of retinopathy of prematurity. *Ophthalmology*. 128(10):e51–e68. doi:10.1016/j.ophtha.2021.05.031.
- He K, Zhang X, Ren S, Sun J. 2016. Deep residual learning for image recognition. Di dalam: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, hlm 770–778. doi:10.1109/CVPR.2016.90.
- Huang G, Sun Y, Liu Z, Sedra D, Weinberger K. 2016. Deep networks with stochastic depth. Di dalam: *European Conference on Computer Vision*, hlm 646–661. doi:10.1007/978-3-319-46493-0_39.
- Khandouzi A, Ariaifar A, Mashayekhi Z, Rahati S, Mirzaei H. 2022. Retinal vessel segmentation, a review of classic and deep methods. *Annals of Biomedical Engineering*. 50:1292–1314. doi:10.1007/s10439-022-02918-5.
- Lin T, Goyal P, Girshick R, He K, Dollár P. 2017. Focal loss for dense object detection. Di dalam: *Proceedings of the IEEE International Conference on Computer Vision*, hlm 2980–2988. doi:10.1109/ICCV.2017.324.
- Loshchilov I, Hutter F. 2019. Decoupled weight decay regularization. Di dalam: *International Conference on Learning Representations (ICLR)*.
- Meijering E, Jacob M, Sarria J, Steiner P, Hirling H, Unser M. 2004. Design and validation of a tool for neurite tracing and analysis in fluorescence microscopy images. *Cytometry Part A*. 58(2):167–176. doi:10.1002/cyto.a.20022.
- Rahim S, Sabri K, Ells A, Wassyng A, Lawford M, He W, Chu L. 2024. Image pre-processing for improving deep learning classification of retinopathy of prematurity. *arXiv preprint arXiv:2302.02524*.
- Ronneberger O, Fischer P, Brox T. 2015. U-Net: Convolutional networks for biomedical image segmentation. Di dalam: *International Conference on Medical Image Computing and Computer-Assisted Intervention*, hlm 234–241. doi:10.1007/978-3-319-24574-4_28.
- Sørensen T. 1948. A method of establishing groups of equal amplitude in plant sociology based on similarity of species and its application to analyses of the vegetation on Danish commons. *Kongelige Danske Videnskabernes Selskab*. 5(4):1–34.
- Tian F, Li Y, Wang J, Chen W. 2021. Blood vessel segmentation of fundus retinal images based on improved Frangi and mathematical morphology. *Computational and Mathematical Methods in Medicine*. 2021:4761517. doi:10.1155/2021/4761517.

- Tong Y, Lu W, Deng Q, Chen C, Shen Y. 2020. Automated identification of retinopathy of prematurity by image-based deep learning. *Eye and Vision*. 7:40. doi:10.1186/s40662-020-00206-2.
- Vahidmoghadam M, Ghorbani P, Ahmadi M, Asadi Khameneh E, Tavassoli B, Taghirad H. 2026. Automated diagnosis of plus form and early stages of ROP using deep learning models. *Scientific Reports*. 16:7234. doi:10.1038/s41598-026-37064-2.
- Yun S, Han D, Oh S, Chun S, Choe J, Yoo Y. 2019. CutMix: Regularization strategy to train strong classifiers with localizable features. Di dalam: *Proceedings of the IEEE International Conference on Computer Vision*, hlm 6023–6032. doi:10.1109/ICCV.2019.00612.
- Zhang H, Cisse M, Dauphin Y, Lopez-Paz D. 2018. mixup: Beyond empirical risk minimization. Di dalam: *International Conference on Learning Representations (ICLR)*.
- Zhang J, Liu Y, Mitsuhashi T, Tsuda T. 2021. Accuracy of deep learning algorithms for the diagnosis of retinopathy of prematurity by fundus images: a systematic review and meta-analysis. *BioMed Research International*. 2021:8883946. doi:10.1155/2021/8883946.
- Zhao X, Chen S, Zhang S, Liu Y, Hu Y, Yuan D, Xie L, Luo X, Zheng M, Tian R, Chen Y, Tan T, Yu Z, Sun Y, Wu Z, Zhang G. 2024. A fundus image dataset for intelligent retinopathy of prematurity system. *Scientific Data*. 11:543. doi:10.1038/s41597-024-03362-5.

LAMPIRAN

Lampiran 1 Konfigurasi *Hyperparameter* Model TinyResNetV2 pada Eksperimen Terbaik

Parameter	Nilai
Arsitektur	TinyResNetV2 (3 stage residual)
Lebar kanal	48 / 96 / 192
Ukuran input	224×224 piksel
Jumlah kelas	5
Fungsi kerugian	Focal Loss ($\gamma = 1,0$)
Bobot kelas	Berbanding terbalik dengan frekuensi
Optimizer	AdamW
Laju belajar	10^{-3}
Peluruhan bobot	5×10^{-4}
Penjadwalan LR	<i>Cosine annealing</i>
Jumlah epoch	160
Ukuran batch	32
Augmentasi MixUp	$\alpha = 0,2, p = 0,5$
Augmentasi CutMix	$\alpha = 1,0, p = 0,5$
<i>Label smoothing</i>	0,1
<i>Stochastic depth</i>	$0 \rightarrow 0,2$
Weight EMA decay	0,999
Protokol CV	StratifiedGroupKFold, 5 fold
Platform komputasi	Modal (A100-80GB)

Lampiran 2 Konfigurasi Pipeline Segmentasi Pembuluh Darah Terbaik
(*g40_m60_fine*)

Parameter	Nilai
Kanal sumber	Kanal hijau (G) dari RGB
CLAHE pertama	<i>Clip limit</i> 6,0; <i>tile</i> 16×16
Preprocessing top-hat	Kernel elips, jari-jari 5 piksel
Gabor: sigma	1,5; 2,5; 3,5; 5,0 piksel
Gabor: lambda	3; 5; 7; 10 piksel
Gabor: sudut	12 sudut (0–165, langkah 15)
Median blur	Kernel 7×7
CLAHE kedua	<i>Clip limit</i> 12,0; <i>tile</i> 12×12
Meijering: sigma halus	0,8; 1,4; 2,0; 2,8; 3,6; 4,5 piksel
Formula fusi	$0,40 \times \text{gabor_tophat} + 0,60 \times \text{meijering_fine}$
Ambang batas	Persentil P0,16 dengan erosi FOV
Seleksi komponen	3 komponen terhubung terbesar
Penutupan morfologis	Ellips 3×3 , 1 iterasi
Hasil Dice (set pengujian)	0,4739

Lampiran 3 Distribusi Lengkap Dataset Zhao2024 dan Statistik Kelompok

Kelas	Jumlah Citra	Persentase	Jumlah Kelompok
Laser Scars	343	31,2%	343 (singleton)
Stage 3	261	23,7%	~120
Normal	236	21,5%	~100
Stage 2	165	15,0%	~80
Stage 1	94	8,6%	~79
Total	1.099	100%	~721

Catatan: jumlah kelompok merupakan perkiraan berdasarkan analisis $NCC \geq 0,99$.

Bekas luka laser (*laser scars*) diperlakukan sebagai *singleton group* karena tidak memiliki kecocokan di kelas lain.